

Resumo para a banca — Benchmark, código e abordagem

Baseado no código (`experiments/drone_routing.py` , `plot_results.py` , `analyze_review.py`), nas instâncias e nos CSVs de resultado. O artigo é usado apenas como referência.

1. O benchmark de origem: E-VRPTW (Schneider/Goeke)

Partimos do conjunto de instâncias do **Electric Vehicle Routing Problem with Time Windows (E-VRPTW)** de Schneider et al. (2014), na versão de dados de Goeke (2019). Ele é derivado das clássicas instâncias de Solomon do VRPTW.

O que cada instância contém (formato em

`data/raw/evrptw/instances/evrptw_instances/c101C5.txt`):

- Um **depósito** único (`Type = d`);
- **Estações de recarga** (`Type = f`) — incluindo uma estação na posição do próprio depósito;
- **Clientes** (`Type = c`) com coordenadas (`x` , `y`), **demanda**, **janela de tempo** [`ReadyTime` , `DueDate`] e **tempo de serviço**;
- Parâmetros globais de energia: capacidade de bateria `Q` , capacidade de carga `C` , taxa de consumo `r` , taxa inversa de recarga `g` e velocidade `v` .

Tamanho usado: 92 instâncias — **36 pequenas** (5, 10 ou 15 clientes) e **56 grandes** (100 clientes). O parser (`parse_instance`) lê cada arquivo, separa depósito/estações/clientes e ordena os clientes por índice. Distâncias são **euclidianas** (`distance`).

2. O que modificamos no benchmark

O E-VRPTW original é **mono-período** e assume infraestrutura **fixa e disponível desde o início**. Nós o reinterpretamos como um problema multi-período de drones (que chamamos **PRMD-ER**):

Aspecto	Original E-VRPTW	Nossa reinterpretação
Veículo	Veículo elétrico terrestre	Drone (margem energética mais apertada)
Horizonte	1 período	H = 4 períodos
Clientes	Todos ativos	Crescem por período: $C_t \subseteq C_{t+1}$, $ C_t = \lceil C \cdot t/H \rceil$
Estações	Todas fixas	3 políticas de disponibilização: depot, phased (gradual), all (completa)
Energia	Parâmetros Q, r, g da instância	Bateria própria do drone medida em distância ($B=80$)
Janelas / autonomia	Restrições rígidas	Restrições flexíveis (penalidades); só capacidade de carga é rígida

Pontos importantes para ser transparente com a banca:

- A **ativação de clientes** (`active_customers`) usa ordenação **angular** em torno do depósito (cenário `spatial`, default) — simula a área atendida crescendo por setores.
- A **seleção gradual de estações** (`select_stations`) é **gulosa**: a cada estação adicionada, escolhe a que mais reduz a soma das distâncias dos clientes ativos à estação mais próxima. Esse **acoplamento demanda↔infraestrutura** é o que não existe no E-VRPTW puro.
- Usamos parâmetros próprios do drone (`DroneParams`: capacidade 50, $B=80$, velocidade 1, recarga com custo fixo + proporcional) em vez dos $Q/C/r/g$ nativos da instância — os campos da instância são lidos, mas a energética é a do drone. Isso é uma escolha deliberada de modelagem e está listada como limitação no artigo.

3. Pipeline do código (`run_experiment`)

Para cada instância → cada período (1..4) → cada política de estação → cada algoritmo:

1. **Ativa clientes** do período (`active_customers`);
2. **Seleciona estações** disponíveis (`select_stations`);
3. **Constrói rotas** (`build_routes`) — passando a solução do período anterior como *warm start* (herança), via `route_history`;
4. **Avalia** (`evaluate`) e grava métricas + tempo de execução.

Saída: `results.csv` (linha a linha) + três sumários agregados (`summary.csv`, `station_policy_summary.csv`, `algorithm_station_summary.csv`).

4. Função objetivo e avaliação (`evaluate`)

A avaliação **simula** cada rota: percorre os vértices, acumula tempo, atualiza bateria e, quando um arco excede a autonomia, tenta inserir **uma** parada de recarga (`insert_recharge`) — a estação ativa

que minimiza o desvio $d_{if} + d_{fj} - d_{ij}$. Se nenhuma estação resolve, o arco é contado como **inviável**.

$$F = D + \alpha \cdot A + \gamma \cdot R + \beta \cdot I$$

com **distância** D , **atraso** A ($\alpha=10$), **nº de rotas** R ($\gamma=100$) e **trechos inviáveis** I ($\beta=10^6$). O β é deliberadamente dominante: uma solução com trecho energeticamente inviável nunca deve "ganhar" de uma viável só por ter menos distância. Janelas são **soft** (espera se chega cedo; penaliza atraso); capacidade de carga é **hard**.

5. Os 9 algoritmos comparados (`build_routes`)

Todos produzem **só a sequência de clientes**; as recargas são reconstruídas pelo módulo de reparo compartilhado — isso torna a comparação justa.

- **Construtivos:** `EDD` (ordena por fim da janela), `Sweep` (ângulo polar), `Nearest` (vizinho mais próximo guloso);
- **GRASP:** construção gulosa-randomizada (lista restrita de 3) + 2-opt, com 20 *restarts*;
- **ALNS** (`alns_routes`): a referência. 3 operadores de destruição (aleatória, pior, por relação espacial), 2 de reparo (guloso e *regret-2*), aceitação por *simulated annealing* e pesos adaptativos pelo esquema- σ de Ropke & Pisinger;
- **MP-EAVNS** (método principal) + **3 variantes de ablação** (sem herança, sem perturbação, sem 2-opt auxiliar).

MP-EAVNS — `energy_aware_vns`

É uma **Variable Neighborhood Search sensível à energia e multi-período**:

1. **Sementes:** melhor entre herança (período anterior) + `EDD` + `Sweep` + `Nearest` + construções randomizadas do GRASP;
2. **5 vizinhanças** encadeadas (*first-improvement*): `N1` 2-opt intra-rota, `N2` realocação, `N3` troca, `N4` divisão de rota, `N5` união de rotas;
3. **Reparo energético** embutido na avaliação;
4. **Perturbação (`shake`)** quando estagna — forçada após 4 iterações sem melhora; até `k_max = 80` iterações;
5. **Herança entre períodos** (`warm_start_routes`): copia rotas do período anterior, remove clientes inativos e insere os novos na posição de menor aumento marginal.

6. Resultados principais (B=80, 9.936 execuções)

- **Viabilidade:** MP-EAVNS atinge **100%** sob política Completa e **98,6%** sob Gradual (empata com ALNS); construtivos ficam abaixo de 52%.

- **Qualidade da rota (só viáveis):** MP-EAVNS produz rotas **6,7% mais curtas que ALNS** (Completa) e 6,2% (Gradual).
 - **Objetivo penalizado:** 36% menor que GRASP; 8,4% acima da ALNS no agregado — mas essa diferença vem **só do regime Depósito** (sem estações); restringindo a Gradual+Completa, MP-EAVNS fica até 0,7% abaixo da ALNS.
 - **Achado central:** a disponibilização **gradual** recupera quase todo o benefício — distância viável apenas **1,4% acima** da Completa.
 - **Custo:** MP-EAVNS ~3,7s/solução vs. ~14,4s da ALNS ($\approx 4\times$ mais rápida) e ~0,35s do GRASP.
 - **Ablação:** a **herança** é o componente mais crítico (removê-la piora o objetivo ~20%); 2-opt auxiliar e perturbação têm efeito pequeno (<1%).
-

7. Perguntas esperadas da banca + respostas

1. Por que reutilizar o E-VRPTW em vez de criar instâncias próprias? Porque é um benchmark consolidado, derivado de Solomon, amplamente usado e com depósito, clientes, janelas, demandas e estações já validados. Isso dá comparabilidade e reprodutibilidade. A literatura de UAV+recarga frequentemente improvisa instâncias derivadas de Solomon justamente por falta de benchmark padronizado — nós aproveitamos um existente e só adicionamos a dimensão multi-período.

2. Vocês usaram os parâmetros de energia das instâncias (Q , r , g)? Não diretamente. Lemos esses campos, mas adotamos um modelo energético próprio do drone, com **bateria medida em unidades de distância** ($B=80$) e consumo proporcional à distância. É uma simplificação deliberada — consistente com a natureza geométrica do E-VRPTW — e está declarada como limitação. Não modela carga, vento, altitude nem pouso/decolagem.

3. Por que tratar autonomia e janelas como penalidades, e não como restrições rígidas? Para distinguir **inviabilidade estrutural** (a infraestrutura não basta) de **inviabilidade algorítmica** (a busca não encontrou solução viável apesar da infraestrutura). Com restrições rígidas, soluções parcialmente inviáveis seriam simplesmente descartadas e não conseguiríamos medir *o quão perto* da viabilidade cada método chega. A capacidade de carga, por outro lado, é fácil de respeitar sempre, então fica rígida.

4. O peso $\beta = 10^6$ não distorce a análise? Ele domina o objetivo de propósito: garante que nenhuma solução inviável vença uma viável. Por isso reportamos as métricas **separadas** — taxa de viabilidade e distância **restrita a soluções viáveis** — neutralizando β e isolando o desempenho puro de roteamento. As conclusões de qualidade vêm dessas métricas, não do objetivo agregado.

5. Qual a diferença real entre MP-EAVNS e ALNS, já que a ALNS é mais conhecida? São filosofias diferentes: ALNS usa **destruição-reconstrução** adaptativa em grandes vizinhanças; a MP-EAVNS alterna **5 vizinhanças locais estruturadas** + perturbação. No nosso problema elas empatam em viabilidade, mas a MP-EAVNS gera rotas viáveis ~6,7% mais curtas e é ~4 $\times$ mais rápida. A vantagem vem sobretudo da **herança entre períodos**, que dá um ponto de partida muito melhor nas instâncias grandes (vence 88,8% dos pares).

6. A comparação de tempo é justa, se ALNS e MP-EAVNS têm operadores diferentes? Igualamos o **número de iterações** ($k_{\max} = 80$), não o tempo de CPU. Reportamos os dois: sob mesmo

orçamento de iterações, a MP-EAVNS ainda sai mais rápida e com rotas melhores. Reconhecemos que comparação por CPU seria outra leitura — está como nota no texto.

7. Por que a ablação "sem herança" piora tanto e as outras quase nada? Porque a herança transporta estrutura útil entre períodos consecutivos — sem ela, cada período recomeça do zero (Nearest) e perde a otimização acumulada, sobretudo nos períodos finais com mais clientes. Já o 2-opt auxiliar é redundante com a vizinhança **N1**, e a perturbação raramente é acionada quando as 5 vizinhanças já esgotaram as melhorias.

8. Por que o reparo energético insere só uma estação por arco? É uma decisão de custo computacional e de design: o reparo é **guloso por arco**, minimizando o desvio local. Arcos que exigiriam duas ou mais recargas são marcados como inviáveis. Nos experimentos com **B≥80** sob política Completa isso nunca impede a viabilidade ($I=0$ em todas as execuções), então a simplificação não compromete os resultados no regime de interesse.

9. Como sabem que o ganho não é só ruído estatístico? Fizemos comparação **pareada** MP-EAVNS×ALNS em soluções viáveis sob Completa: vantagem média de 76,9 unidades de distância com IC 95% [65,4; 88,4] — intervalo que não cruza zero. Nas pequenas há empate técnico (esperado, poucos clientes); o ganho real está nas grandes.

10. O cenário "gradual" é realista? Sim — é a motivação do trabalho. Uma rede de entrega por drones cresce gradualmente: novos clientes e novas estações entram com o tempo. A pergunta prática é "quanto desempenho dá pra preservar antes da infraestrutura total estar pronta", e a resposta foi: quase tudo (98,6% de viabilidade, distância só 1,4% pior que a infraestrutura completa).